

Mashinaviy o'qitishda ma'lumotlarni tozalash (Data Cleaning in ML)

Ma'lumotlarni tozalash (**Data cleaning**) — bu **yetishmayotgan, takrorlanuvchi** yoki **nomaqbul** (keraksiz) ma'lumotlarni aniqlash va ularni olib tashlashni o'z ichiga olgan mashinaviy o'qitish (ML) qadamidir.

Xom ma'lumotlar (log fayllar, tranzaksiyalar, audio/video yozuvlar va hokazo) ko'pincha **shovqinli, to'liq emas** va **nomuvofiq** bo'ladi, bu esa modelning aniqligiga salbiy ta'sir ko'rsatishi mumkin.

Ma'lumotlarni tozalashdan maqsad – ma'lumotlarning **aniq, izchil** va **xatolardan xoli** bo'lishini ta'minlash.

Toza ma'lumotlar to'plami **EDA** (Exploratory Data Analysis – Tahliliy Ma'lumotlarni O'rganish) uchun ham muhimdir, bu ma'lumotlarning **talqin qilinishini** oshiradi, shunda olingan tahlillar (insights) asosida to'g'ri choralar ko'rilishi mumkin.



Bu rasm ma'lumotlarni tozalashning (Data Cleaning) **foydalarini** (Benefits of Data Cleaning) tasvirlaydi. Ular:

1. **Xatosiz ma'lumotlar (Error Free Data):** Ma'lumotlardagi xatolarning bartaraf etilishini bildiradi.
2. **Ma'lumot sifati (Data Quality):** Ma'lumotlarning umumiy sifatini oshirish.
3. **Aniqlik va Samaradorlik (Accuracy & Efficiency):** Jarayonlarning aniqligi va samaradorligini yaxshilash.
4. **To'liq ma'lumotlar (Complete Data):** Ma'lumotlar to'plamining to'liqligini ta'minlash.

5. Ma'lumotlar muvofiqligini ta'minlaydi (Maintains Data Consistency): Ma'lumotlar bir-biriga mosligini va izchil ekanligini saqlash.

Rasm ma'lumotlarni tozalashning ML va tahlil (analysis) uchun qanchalik muhimligini vizual tarzda ko'rsatib beradi.

Ma'lumotlarni tozalashni (Data Cleaning) amalga oshirish

Jarayon yetishmayotgan qiymatlar (*missing values*), takrorlanuvchi ma'lumotlar (*duplicates*) va chetga chiqqan qiymatlar (*outliers*) kabi muammolarni aniqlashdan boshlanadi. Ma'lumotlarni tozalashni amalga oshirish ma'lumotlar to'plamida (dataset) xatolarni aniqlash va olib tashlashning tizimli jarayonini o'z ichiga oladi.

Ma'lumotlarni tozalashni bajarish uchun quyidagi qadamlar muhimdir:

- **Keraksiz kuzatuvlarni olib tashlash** (*Remove Unwanted Observations*): "Shovqin" (*noise*) qo'shadigan takrorlanuvchi ma'lumotlarni (*duplicates*), nomaqbul yozuvlarni (*irrelevant entries*) yoki ortiqcha ma'lumotlarni (*redundant data*) yo'q qiling.

- **Strukturaviy xatolarni tuzatish** (*Fix Structural Errors*): Izchillik (*consistency*) uchun ma'lumot formatlarini va o'zgaruvchi turlarini (*variable types*) standartlashtiring.

- **Chetga chiqqan qiymatlarni boshqarish** (*Manage Outliers*): Natijalarni buzib yuborishi (*skew results*) mumkin bo'lgan o'ta chekka qiymatlarni (*extreme values*) aniqlang va ularni olib tashlash yoki o'zgartirish (*transformation*) orqali hal qiling.

- **Yetishmayotgan ma'lumotlarni hal qilish** (*Handle Missing Data*): Aniqlik (*accuracy*) va yaxlitlikni (*integrity*) saqlash uchun bo'shliqlarni to'ldirish (*imputation*), o'chirish (*deletion*) yoki ilg'or usullar (*advanced techniques*) yordamida hal qiling.

Ma'lumotlarni tozalashni amalga oshirish

(Implementation for Data Cleaning)

Keling, har bir qadamni "Titanik" ma'lumotlar to'plami (*titanic dataset*) yordamida Ma'lumotlar bazasini tozalash (*Database Cleaning*) uchun tushunib chiqamiz.

	PassengerId	Survived	Pclass	Name	Sex	Age	SibSp	Parch	Ticket	Fare	Cabin	Embarked
1	1	0	3	Braund, Mr. Owen Harris	male	22	1	0	A/5 21171	7.25		S
2	2	1	1	Cumings, Mrs. John Bradley (Florence Briggs Thayer)	female	38	1	0	PC 17599	71.2833	C85	C
3	3	1	3	Heikkinen, Miss. Laina	female	26	0	0	ON/O2. 3101282	7.925		S
4	4	1	1	Futrelle, Mrs. Jacques Heath (Lily May Peel)	female	35	1	0	113803	53.1	C123	S
5	5	0	3	Allen, Mr. William Henry	male	35	0	0	373450	8.05		S
6	6	0	3	Moran, Mr. James	male		0	0	330877	8.4583		Q
7	7	0	1	McCarthy, Mr. Timothy J	male	54	0	0	17463	51.8625	E46	S
8	8	0	3	Palsson, Master. Gosta Leonard	male	2	3	1	349909	21.075		S
9	9	1	3	Johnson, Mrs. Oscar W (Elisabeth Vilhelmina Berg)	female	27	0	2	347742	11.1333		S
10	10	1	2	Nasser, Mrs. Nicholas (Adele Achem)	female	14	1	0	237736	30.0708		C
11	11	1	3	Sandstrom, Miss. Marguerite Rut	female	4	1	1	PP 9549	16.7	G6	S
12	12	1	1	Bonnell, Miss. Elizabeth	female	58	0	0	113783	26.55	C103	S
13	13	0	3	Saunderscock, Mr. William Henry	male	20	0	0	A/5. 2151	8.05		S
14	14	0	3	Andersson, Mr. Anders Johan	male	39	1	5	347082	31.275		S
15	15	0	3	Vestrom, Miss. Hulda Amanda Adolfina	female	14	0	0	350406	7.8542		S
16	16	1	2	Hewlett, Mrs. (Mary D Kingcome)	female	55	0	0	248706	16		S
17	17	0	3	Rice, Master. Eugene	male	2	4	1	382652	29.125		Q
18	18	1	2	Williams, Mr. Charles Eugene	male		0	0	244373	13		S
19	19	0	3	ander Planke, Mrs. Julius (Emelia Maria Vandemoortele)	female	31	1	0	345763	18		S
20	20	1	3	Masselmani, Mrs. Fatima	female		0	0	2649	7.225		C
21	21	0	2	Fynney, Mr. Joseph J	male	35	0	0	239865	26		S
22	22	1	2	Beesley, Mr. Lawrence	male	34	0	0	248698	13	D56	S
23	23	1	3	McGowan, Miss. Anna "Annie"	female	15	0	0	330923	8.0292		Q
24	24	1	1	Sloper, Mr. William Thompson	male	28	0	0	113788	35.5	A6	S
25	25	0	3	Palsson, Miss. Torborg Danira	female	8	3	1	349909	21.075		S

1-Qadam: Kutubxonalarni import qilish va ma'lumotlar to'plamini yuklash (Import Libraries and Load Dataset)

Biz barcha kerakli kutubxonalarni, ya'ni **pandas** va **numpy** ni import qilamiz.

```
import pandas as pd
import numpy as np

df = pd.read_csv('Titanic-Dataset.csv')
df.info()
df.head()
```

Chiqish:

```
<class 'pandas.core.frame.DataFrame'>
RangeIndex: 891 entries, 0 to 890
Data columns (total 12 columns):
#   Column      Non-Null Count  Dtype
---  ---
0   PassengerId  891 non-null    int64
1   Survived    891 non-null    int64
2   Pclass      891 non-null    int64
3   Name        891 non-null    object
4   Sex         891 non-null    object
5   Age         714 non-null    float64
6   SibSp       891 non-null    int64
7   Parch       891 non-null    int64
8   Ticket      891 non-null    object
9   Fare        891 non-null    float64
10  Cabin       204 non-null    object
11  Embarked    889 non-null    object
dtypes: float64(2), int64(5), object(5)
memory usage: 83.7+ KB
```

	PassengerId	Survived	Pclass	Name	Sex	Age	SibSp	Parch	Ticket	Fare	Cabin	Embarked
0	1	0	3	Braund, Mr. Owen Harris	male	22.0	1	0	A/5 21171	7.2500	NaN	S
1	2	1	1	Cumings, Mrs. John Bradley (Florence Briggs Th...	female	38.0	1	0	PC 17599	71.2833	C85	C
2	3	1	3	Heikkinen, Miss. Laina	female	26.0	0	0	STON/O2. 3101282	7.9250	NaN	S
3	4	1	1	Futrelle, Mrs. Jacques Heath (Lily May Peel)	female	35.0	1	0	113803	53.1000	C123	S
4	5	0	3	Allen, Mr. William Henry	male	35.0	0	0	373450	8.0500	NaN	S

2-Qadam: Takrorlanuvchi Qatorlarni Tekshirish (Check for Duplicate Rows)

`df.duplicated()`: Takrorlanuvchi qatorlarni (*duplicate rows*) ko'rsatuvchi mantiqiy qatorni (*boolean Series*) qaytaradi.

```
df.duplicated()
```

```
0      False
1      False
2      False
3      False
4      False
...
886    False
887    False
888    False
889    False
890    False
Length: 891, dtype: bool
```

3-Qadam: Ustun ma'lumot turlarini aniqlash (Identify Column Data Types)

Kategorik (*categorical*) va raqamli (*numerical*) ustunlarni ajratish uchun **.dtype** atributi bilan ro'yxatni tushunish (*List comprehension*) usulidan foydalanamiz.

object ma'lumot turi (*dtype*): Odatda matn (*text*) yoki kategorik ma'lumotlar (*categorical data*) uchun ishlatiladi.

```
cat_col = [col for col in df.columns if df[col].dtype == 'object']
num_col = [col for col in df.columns if df[col].dtype != 'object']

print('Categorical columns:', cat_col)
print('Numerical columns:', num_col)
```

```
Categorical columns: ['Name', 'Sex', 'Ticket', 'Cabin', 'Embarked']
```

```
Numerical columns: ['PassengerId', 'Survived', 'Pclass', 'Age', 'SibSp', 'Parch', 'Fare']
```

4-Qadam: Kategorik Ustunlardagi Noyob Qiymatlarni Sanash (Count Unique Values in the Categorical Columns)

`df[numeric_columns].nunique()`: Har bir ustun uchun **noyob qiymatlar** (*unique values*) sonini qaytaradi.

```
df[cat_col].nunique()
```

```
Name      891
Sex         2
Ticket     681
Cabin      147
Embarked    3
dtype: int64
```

5-Qadam: Yetishmayotgan Qiymatlarni Foizda Hisoblash (Calculate Missing Values as Percentage)

`df.isnull()`: Yetishmayotgan qiymatlarni (*missing values*) aniqlaydi va mantiqiy ma'lumotlar ramkasini (*boolean DataFrame*) qaytaradi.

Yetishmayotgan qiymatlarni ustunlar bo'yicha yig'ing (*Sum*), jami qatorlar soniga normallashtiring (*normalize by total rows*) va 100 ga ko'paytiring.

```
round((df.isnull().sum() / df.shape[0]) * 100, 2)
```

PassengerId	0.00
Survived	0.00
Pclass	0.00
Name	0.00
Sex	0.00
Age	19.87
SibSp	0.00
Parch	0.00
Ticket	0.00
Fare	0.00
Cabin	77.10
Embarked	0.22
dtype:	float64

6-Qadam: Nomaqbul yoki ko'p ma'lumot yetishmaydigan ustunlarni olib tashlash (Drop Irrelevant or Data-Heavy Missing Columns)

- `df.drop(columns=[])`: Ma'lumotlar Ramkasidan (*DataFrame*) ko'rsatilgan ustunlarni (*columns*) olib tashlaydi.

- `df.dropna(subset=[])`: Ko'rsatilgan ustunlarda yetishmayotgan qiymatlar (*missing values*) mavjud bo'lgan qatorlarni (*rows*) olib tashlaydi.

- `fillna()`: Yetishmayotgan qiymatlarni ko'rsatilgan qiymat (*specified value*) bilan to'ldiradi (masalan, o'rtacha qiymat (*mean*) bilan).

```
df1 = df.drop(columns=['Name', 'Ticket', 'Cabin'])
df1.dropna(subset=['Embarked'], inplace=True)
df1['Age'].fillna(df1['Age'].mean(), inplace=True)
```


7-Qadam: Quti diagrammasi (box plot) yordamida chetga chiqqan qiymatlarni aniqlash (Detect Outliers with Box Plot)

- `matplotlib.pyplot.boxplot()`: Ma'lumotlar taqsimotini (*distribution of data*) ko'rsatadi, bunda **medianani** (*median*), **kvartillarni** (*quartiles*) va **chetga chiqqan qiymatlarni** (*outliers*) ajratib ko'rsatadi.

- `plt.show()`: Grafikni **aks ettiradi** (*Renders the plot*).

```
import matplotlib.pyplot as plt

plt.boxplot(df1['Age'], vert=False)
plt.ylabel('Variable')
plt.xlabel('Age')
plt.title('Box Plot')
plt.show()
```



8-Qadam: Chetga chiqqan qiymatlar chegaralarini hisoblash va ularni olib tashlash (Calculate Outlier Boundaries and Remove Them)

- `df['Age'].mean()` va `df['Age'].std()` yordamida oʻrtacha qiymat (*mean*) va standart ogʻishni (*standard deviation (std)*) hisoblang.
- Chetga chiqqan qiymatlarni aniqlash uchun chegaralarni (*bounds*) $mean \pm 2 * std$ deb belgilang.
- Mantiqiy indekslash (*Boolean indexing*) yordamida ma'lumotlar ramkasidagi (*DataFrame*) chegaralar ichida boʻlgan qatorlarni filtrlang (*Filter*).

```
mean = df1['Age'].mean()
std = df1['Age'].std()

lower_bound = mean - 2 * std
upper_bound = mean + 2 * std

df2 = df1[(df1['Age'] >= lower_bound) & (df1['Age'] <= upper_bound)]
```

9-Qadam: Agar qolgan bo'lsa, yetishmayotgan ma'lumotlarni qayta to'ldirish (Impute Missing Data Again if Any)

Qolgan yetishmayotgan qiymatlarni (*remaining missing values*) hal qilish uchun filtrdan o'tkazilgan ma'lumotlarga (*filtered data*) `fillna()` usuli qaytadan qo'llaniladi.

```
df3 = df2.fillna(df2['Age'].mean())  
df3.isnull().sum()
```

Chiqish:

```
PassengerId    0  
Survived        0  
Pclass         0  
Sex            0  
Age            0  
SibSp          0  
Parch          0  
Fare           0  
Embarked       0  
dtype: int64
```

10-Qadam: Yangilangan ma'lumotlardagi chetga chiqqan qiymatlar chegaralarini qayta hisoblash va ularni olib tashlash (Recalculate Outlier Bounds and Remove Outliers from the Updated Data)

- `mean = df3['Age'].mean()`: df3 Ma'lumotlar Ramkasidagi (*DataFrame*) "Age" ustunining o'rtacha (*average (mean)*) qiymatini hisoblaydi.

- `std = df3['Age'].std()`: df3 dagi "Age" ustunining standart og'ishini (*standard deviation (spread or variability)*) hisoblaydi.

- `lower_bound = mean - 2 * std`: Ruxsat etilgan "Age" qiymatlari uchun quyi chegarani (*lower limit*) belgilaydi, bu o'rtacha qiymatdan (*mean*) ikki standart og'ish (*two standard deviations*) past qilib o'rnatiladi.

- `upper_bound = mean + 2 * std`: Ruxsat etilgan "Age" qiymatlari uchun yuqori chegarani (*upper limit*) belgilaydi, bu o'rtacha qiymatdan (*mean*) ikki standart og'ish (*two standard deviations*) yuqori qilib o'rnatiladi.

- `df4 = df3[(df3['Age'] >= lower_bound) & (df3['Age'] <= upper_bound)]`: Faqat "Age" qiymati quyi (*lower*) va yuqori (*upper*) chegaralar orasiga tushadigan qatorlarni tanlab, yangi Ma'lumotlar Ramkasi (*DataFrame*) df4 ni yaratadi, shu bilan bu diapazondan tashqaridagi chetga chiqqan yoshlarni (*outlier ages*) samarali ravishda olib tashlaydi.

```
mean = df3['Age'].mean()  
std = df3['Age'].std()
```

```

lower_bound = mean - 2 * std
upper_bound = mean + 2 * std

print('Lower Bound :', lower_bound)
print('Upper Bound :', upper_bound)

df4 = df3[(df3['Age'] >= lower_bound) & (df3['Age'] <= upper_bound)]

```

Chiqish:

```

Lower Bound : 8.978989004171481
Upper Bound : 49.30395961288911

```

11-Qadam: Ma'lumotlarni Tasdiqlash va Tekshirish (Data validation and verification)

Ma'lumotlarni tasdiqlash va tekshirish (*Data validation and verification*) — bu ma'lumotlarni tashqi manbalar (*external sources*) yoki ekspert bilimlari (*expert knowledge*) bilan solishtirish orqali ularning aniq (*accurate*) va izchil (*consistent*) ekanligini ta'minlashni o'z ichiga oladi.

Mashinaviy o'qitish prognozi (*machine learning prediction*) uchun biz mustaqil (*independent*) va maqsadli (*target*) xususiyatlarni ajratamiz. Bu yerda biz faqat 'Sex' (Jinsi), 'Age' (Yoshi), 'SibSp' (Aka-uka/Turmush o'rtog'i soni), 'Parch' (Ota-onalar/Bolalar soni), 'Fare' (Yo'l haqi), 'Embarked' (Kemaga chiqish porti) ustunlarini mustaqil xususiyatlar (*independent features*) va 'Survived' (Omon qolgan) ustunini maqsadli o'zgaruvchi (*target variable*) deb hisoblaymiz, chunki 'PassengerId' (Yo'lovchi ID) omon qolish darajasiga ta'sir qilmaydi.

```

X = df3[['Pclass', 'Sex', 'Age', 'SibSp', 'Parch', 'Fare', 'Embarked']]
Y = df3['Survived']

```

12-Qadam: Ma'lumotlarni formatlash (Data formatting)

Ma'lumotlarni formatlash (*Data formatting*) — bu ma'lumotlarni tahlil qilish uchun ishlatiladigan **algoritmlar** (*algorithms*) yoki **modellar** (*models*) tomonidan osongina qayta ishlanishi mumkin bo'lgan standart **format** (*format*) yoki **strukturaga** (*structure*) o'tkazishni o'z ichiga oladi. Bu yerda biz keng qo'llaniladigan ma'lumotlarni formatlash usullarini, ya'ni **Masshtablash** (*Scaling*) va **Normallashtirishni** (*Normalization*) muhokama qilamiz.

Masshtablash (*Scaling*) — bu xususiyatlarning (*features*) qiymatlarini **muayyan diapazonga** (*specific range*) o'zgartirishni o'z ichiga oladi. U asl taqsimotning **shaklini** (*shape*) saqlab qoladi, shu bilan birga **masshtabni** (*scale*) o'zgartiradi. U xususiyatlar **turli masshtablarda** (*different scales*) bo'lganda va ba'zi

algoritmlar xususiyatlarning **kattaligiga** (*magnitude*) sezgir bo'lganda foydalidir. Keng tarqalgan masshtablash usullari quyidagilarni o'z ichiga oladi:

1. **Min-Max masshtablash** (*Min-Max Scaling*): Min-Max masshtablash qiymatlarni ko'rsatilgan diapazonga, odatda 0 va 1 oralig'iga qayta masshtablaydi (*rescales*). U asl taqsimotni saqlab qoladi va minimal qiymat 0 ga (*minimum value maps to 0*) va maksimal qiymat 1 ga (*maximum value maps to 1*) xaritalanishini (*maps*) ta'minlaydi.

```
from sklearn.preprocessing import MinMaxScaler

scaler = MinMaxScaler(feature_range=(0, 1))

num_col_ = [col for col in X.columns if X[col].dtype != 'object']
x1 = X.copy()
x1[num_col_] = scaler.fit_transform(x1[num_col_])
x1.head()
```

Chiqish:

	Pclass	Sex	Age	SibSp	Parch	Fare	Embarked
0	1.0	male	0.349515	0.125	0.0	0.014151	S
1	0.0	female	0.660194	0.125	0.0	0.139136	C
2	1.0	female	0.427184	0.000	0.0	0.015469	S
3	0.0	female	0.601942	0.125	0.0	0.103644	S
4	1.0	male	0.601942	0.000	0.0	0.015713	S

2. **Standartlashtirish (Z-ko'rsatkichli masshtablash)** (*Standardization (Z-score scaling)*): Standartlashtirish (*Standardization*) qiymatlarni o'rtacha qiymati 0 (*mean of 0*) va standart og'ishi 1 (*standard deviation of 1*) bo'ladigan qilib o'zgartiradi. U ma'lumotlarni o'rtacha qiymat atrofida markazlashtiradi (*centers the data around the mean*) va ularni standart og'ish (*standard deviation*) asosida masshtablaydi (*scales*). Standartlashtirish Gauss taqsimotini (*Gaussian distribution*) taxmin qiladigan yoki xususiyatlarning nol o'rtacha qiymat (*zero mean*) va birlik dispersiyaga (*unit variance*) ega bo'lishini talab qiladigan algoritmlar (*algorithms*) uchun ma'lumotlarni yanada mos qiladi.

$$Z = (X - \mu) / \sigma$$

Bu yerda:

- **X** = Ma'lumot (*Data*)

- μ = X ning o'rtacha qiymati (*Mean value of X*)
- σ = X ning standart og'ishi (*Standard deviation of X*)

Ma'lumotlarni tozalash vositalari (*Data Cleaning Tools*):

- **OpenRefine:** Bepul, ochiq kodli vosita (*free, open-source tool*) bo'lib, noaniq (*messy*) ma'lumotlarni tozalash, o'zgartirish (*transforming*) va boyitish (*enriching*) uchun qulay interfeys (*easy-to-use interface*) hamda klasterlash (*clustering*) va facetlash (*faceting*) kabi kuchli xususiyatlarga ega.

- **Trifacta Wrangler:** Sun'iy intellekt (*AI-powered*) bilan ishlaydigan, foydalanuvchiga qulay platforma (*platform*) bo'lib, tezroq va aniqroq tayyorlash uchun ma'lumotlarni tozalash va o'zgartirish oqimlarini (*transformation workflows*) avtomatlashtirishga yordam beradi.

- **TIBCO Clarity:** Turli manbalar (*diverse sources*) bo'ylab yuqori sifatli, standartlashtirilgan (*standardized*) va izchil (*consistent*) ma'lumotlar to'plamini ta'minlaydigan ma'lumotlarni profilash (*profiling*) va tozalash vositasi.

- **Cloudingo:** Takrorlanuvchi ma'lumotlarni olib tashlash (*deduplication*) va ma'lumotlarni tozalashga qaratilgan bulutga asoslangan yechim (*cloud-based solution*), ayniqsa CRM ma'lumotlarini (*CRM data*) aniq saqlash uchun foydali.

- **IBM InfoSphere QualityStage: Profilash (*profiling*), moslashtirish (*matching*) va tozalash (*cleansing*)** kabi keng ko'lamli, murakkab ma'lumot sifati boshqaruvi (*data quality management*) uchun mo'ljallangan korxona darajasidagi vosita (*enterprise-grade tool*).

Afzalliklar (*Advantages*)

- **Model ishlashining yaxshilanishi (*Improved model performance*):** Xatolar (*errors*), nomuvofiqliklar (*inconsistencies*) va noma'qul ma'lumotlarni olib tashlash modelga ma'lumotlardan yaxshiroq o'rganishga (*better learn*) yordam beradi.

- **Aniqlikning oshishi (*Increased accuracy*):** Ma'lumotlarning aniq, izchil va xatolardan xoli bo'lishini ta'minlashga yordam beradi.

- **Ma'lumotlarning yaxshiroq ifodalanishi (*Better representation of the data*):** Ma'lumotlarni tozalash ma'lumotlardagi asosiy munosabatlar (*underlying relationships*) va namunalarni (*patterns*) yaxshiroq ifodalaydigan formatga o'tkazish imkonini beradi.

- **Ma'lumot sifatining yaxshilanishi (*Improved data quality*):** Ma'lumotlarning sifatini yaxshilaydi, ularni ishonchliroq (*more reliable*) va aniqroq (*accurate*) qiladi.

- **Ma'lumot xavfsizligining yaxshilanishi** (*Improved data security*): Ma'lumotlar xavfsizligini (*data security*) buzishi mumkin bo'lgan sezgir (*sensitive*) yoki maxfiy ma'lumotlarni (*confidential information*) aniqlash va olib tashlashga yordam beradi.

Kamchiliklar (*Disadvantages*)

- **Vaqt talab qiluvchi** (*Time-consuming*): Bu, ayniqsa, katta (*large*) va murakkab ma'lumotlar to'plami (*complex datasets*) uchun juda ko'p vaqt talab qiladigan vazifadir.

- **Xatoga moyil** (*Error-prone*): Bu muhim ma'lumotlarning yo'qolishiga (*loss of important information*) olib kelishi mumkin.

- **Qimmat va resurs talab qiluvchi** (*Cost and resource-intensive*): Bu resurs talab qiluvchi jarayon (*resource-intensive process*) bo'lib, katta vaqt, sa'y-harakat va tajribani (*expertise*) talab qiladi. Shuningdek, u ixtisoslashgan dasturiy ta'minot vositalaridan (*specialized software tools*) foydalanishni talab qilishi mumkin.

- **Haddan tashqari moslashuv** (*Overfitting*): Ma'lumotlarni tozalash juda ko'p ma'lumotni olib tashlash (*removing too much data*) orqali haddan tashqari moslashuvga (*overfitting*) hissa qo'shishi mumkin.

