


Pythonda ma'lumotlarni oldindan qayta ishlash (Data Preprocessing in Python)

Ma'lumotlarni oldindan qayta ishlash (Data preprocessing) — bu har qanday ma'lumotlarni tahlil qilish (*data analysis*) yoki mashinaviy o'qitish oqimining (*machine learning pipeline*) birinchi qadami. U xom ma'lumotlarni (*raw data*) tozalash (*cleaning*), o'zgartirish (*transforming*) va tashkil etishni (*organizing*) o'z ichiga oladi, bu esa ma'lumotlarning aniq, izchil (*consistent*) va modellashtirishga tayyor (*ready for modeling*) bo'lishini ta'minlaydi. U model yaratishga (*model building*) katta ta'sir ko'rsatadi, masalan:

- Toza (*Clean*) va yaxshi tuzilgan ma'lumotlar (*well-structured data*) modellarga shovqindan (*noise*) ko'ra mazmunli namunalarni (*meaningful patterns*) o'rganishga imkon beradi.
- To'g'ri qayta ishlangan ma'lumotlar (*Properly processed data*) chalg'ituvchi kirishlarning (*misleading inputs*) oldini oladi, bu esa ishonchliroq prognozlarga (*more reliable predictions*) olib keladi.
- Tashkil etilgan ma'lumotlar (*Organized data*) model uchun foydali kirishlarni yaratishni (*create useful inputs*) soddalashtiradi va model samaradorligini (*model performance*) oshiradi.
- Tashkil etilgan ma'lumotlar Yaxshiroq Tahliliy Ma'lumotlarni O'rganishni (*better Exploratory Data Analysis (EDA)*) qo'llab-quvvatlaydi, bu esa namunalar (*patterns*) va tendensiyalarni (*trends*) yanada talqin qilinadigan (*interpretable*) qiladi.



Bu rasm **Ma'lumotlarni oldindan qayta ishlash** (*Data Preprocessing*) jarayonining oltita asosiy komponentini (bosqichini) juftlashtirilgan tartibda ko'rsatadi:

1. **Data Cleaning** (Ma'lumotlarni tozalash): Ma'lumotlardagi xatolar va nomuvofiqliklarni tuzatish.

2. **Sampling Data** (Ma'lumotlarni tanlab olish): Katta ma'lumotlar to'plamidan kichikroq qismini olish.

3. **Dimensionality Reduction** (O'lchovlilikni qisqartirish): Ma'lumotlar to'plamining o'zgaruvchilar (*variables*) sonini kamaytirish.

4. **Data Transformation** (Ma'lumotlarni o'zgartirish): Ma'lumotlarni modellashtirish uchun mos formatga o'tkazish (masalan, masshtablash).

5. **Feature Engineering** (Xususiyatlarni loyihalash): Model samaradorligini oshirish uchun mavjud ma'lumotlardan yangi xususiyatlarni yaratish.

6. **Imbalanced Data** (Nomutanosib ma'lumotlar): Klasslar taqsimoti teng bo'lmagan ma'lumotlar to'plamlarini boshqarish usullari.

Qadam-baqadam amaliyot (*Steps-by-Step Implementation*)

Keling, turli xil oldindan qayta ishlash xususiyatlarini (*preprocessing features*) amalga oshiramiz:

1-Qadam: Kutubxonalarni import qilish va ma'lumotlar to'plamini yuklash (Import Libraries and Load Dataset)

Biz ma'lumotlarga ishlov berish (*data manipulation*), raqamli amallar (*numerical operations*), vizuallashtirish (*visualization*) va masshtablash (*scaling*) uchun *pandas*, *numpy*, *scikit-learn*, *matplotlib* va *seaborn* kabi kutubxonalar bilan muhitni tayyorlaymiz (*prepare the environment*). Oldindan qayta ishlash (*preprocessing*) uchun ma'lumotlar to'plamini (*dataset*) yuklaymiz.

```
import pandas as pd
import numpy as np
from sklearn.preprocessing import MinMaxScaler, StandardScaler
import seaborn as sns
import matplotlib.pyplot as plt

df = pd.read_csv('diabetes.csv')
df.head()
```

Chiqish:

	Pregnancies	Glucose	BloodPressure	SkinThickness	Insulin	BMI	DiabetesPedigreeFunction	Age	Outcome
0	6	148	72	35	0	33.6	0.627	50	1
1	1	85	66	29	0	26.6	0.351	31	0
2	8	183	64	0	0	23.3	0.672	32	1
3	1	89	66	23	94	28.1	0.167	21	0
4	0	137	40	35	168	43.1	2.288	33	1

2-Qadam: Ma'lumotlar strukturasi va yetishmayotgan qiymatlarni tekshirish (Inspect Data Structure and Check Missing Values)

Biz ma'lumotlar to'plamining hajmini (*dataset size*), ma'lumot turlarini (*data types*) tushunamiz va ishlov berishni talab qiladigan har qanday to'liq bo'lmagan (*incomplete*) (yetishmayotgan) ma'lumotlarni (*missing data*) aniqlaymiz.

- `df.info()`: Har bir ustunning bo'sh bo'lmagan yozuvlar sonini (*count of non-null entries*) va ma'lumot turini (*data type*) o'z ichiga olgan ixcham xulosani (*concise summary*) chop etadi.

- `df.isnull().sum()`: Har bir ustundagi yetishmayotgan qiymatlar (*missing values*) sonini qaytaradi.

```
df.info()
print(df.isnull().sum())
```

```
<class 'pandas.core.frame.DataFrame'>
RangeIndex: 768 entries, 0 to 767
Data columns (total 9 columns):
#   Column                Non-Null Count  Dtype
---  -
0   Pregnancies           768 non-null   int64
1   Glucose               768 non-null   int64
2   BloodPressure         768 non-null   int64
3   SkinThickness         768 non-null   int64
4   Insulin               768 non-null   int64
5   BMI                   768 non-null   float64
6   DiabetesPedigreeFunction 768 non-null   float64
7   Age                   768 non-null   int64
8   Outcome               768 non-null   int64
dtypes: float64(2), int64(7)
memory usage: 54.1 KB
Pregnancies           0
Glucose               0
BloodPressure         0
SkinThickness         0
Insulin               0
BMI                   0
DiabetesPedigreeFunction 0
Age                   0
Outcome               0
dtype: int64
```

3-Qadam: Statistik xulosa va chetga chiqqan qiymatlarni vizuallashtirish (Statistical Summary and Visualizing Outliers)


Biz oʻrtacha qiymat (*mean*), median (*median*), minimal/maksimal (*min/max*) kabi raqamli xulosalarni (*numeric summaries*) olamiz va gʻayrioddiy nuqtalarni (*unusual points*) (chetga chiqqan qiymatlarni (*outliers*)) aniqlaymiz. Agar chetga chiqqan qiymatlar (*outliers*) hal etilmasa, ular modellarni buzishi (*skew models*) mumkin.

- `df.describe()`: Raqamli ustunlar (*numerical columns*) uchun sanogʻini (*count*), oʻrtacha qiymatini (*mean*), standart ogʻishni (*std deviation*), minimal/maksimal (*min/max*) va kvartillarni (*quartiles*) hisoblaydi.
- Quti diagrammalari (*Boxplots*): Matplotlib (*matplotlib*) ning `boxplot()` usulidan foydalanib, tarqalishni (*spread*) vizuallashtiradi (*Visualize*) va chetga chiqqan qiymatlarni (*outliers*) aniqlaydi.

```
df.describe()

fig, axs = plt.subplots(len(df.columns), 1, figsize=(7, 18), dpi=95)
for i, col in enumerate(df.columns):
    axs[i].boxplot(df[col], vert=False)
    axs[i].set_ylabel(col)
plt.tight_layout()
plt.show()
```

Chiqish:



4-Qadam: Kvartillararo diapazon (IQR) usulidan foydalanib chetga chiqqan qiymatlarni olib tashlash

(Remove Outliers Using the Interquartile Range (IQR) Method)

Modelning mustahkamligini (*model robustness*) yaxshilash uchun oqilona diapazondan (*reasonable range*) tashqaridagi o'ta chekka qiymatlarni (*extreme values*) olib tashlang.

- $IQR = Q3$ (75th percentile) – $Q1$ (25th percentile).
- $Q1 - 1.5IQR$ dan past yoki $Q3 + 1.5IQR$ dan yuqori bo'lgan qiymatlar chetga chiqqan qiymatlar (*outliers*) hisoblanadi.
- Har bir ustun uchun quyi (*lower*) va yuqori chegaralarni (*upper bounds*) alohida hisoblang.
- Chegaralar ichida bo'lgan ma'lumot nuqtalarini (*data points*) saqlab qolish uchun filtrlang (*Filter*).

```
q1, q3 = np.percentile(df['Insulin'], [25, 75])
iqr = q3 - q1
lower = q1 - 1.5 * iqr
upper = q3 + 1.5 * iqr
clean_df = df[(df['Insulin'] >= lower) & (df['Insulin'] <= upper)]
```

5-Qadam: Korrelyatsiya Tahlili


(Correlation Analysis)

Xususiyatlar (*features*) va maqsadli o'zgaruvchi (*target variable*) (Natija (*Outcome*)) o'rtasidagi bog'liqliklarni (*relationships*) tushuning. Korrelyatsiya (*Correlation*) xususiyatlarning muhimligini o'lchashga (*gauge feature importance*) yordam beradi.

- `df.corr()`: Ustunlar o'rtasidagi juftlik korrelyatsiya koeffitsiyentlarini (*pairwise correlation coefficients*) hisoblaydi.
- Seaborn (*seaborn*) orqali Issiqlik xaritasi (*Heatmap*) korrelyatsiya matritsasini (*correlation matrix*) aniq vizuallashtiradi (*visualizes*).
- `corr['Outcome'].sort_values()` yordamida korrelyatsiyalarni saralash (*Sorting*) maqsadli o'zgaruvchi bilan eng ko'p korrelyatsiyalangan xususiyatlarni (*most correlated features*) ajratib ko'rsatadi.

```
corr = df.corr()
plt.figure(dpi=130)
sns.heatmap(corr, annot=True, fmt='.2f', cmap='coolwarm')
plt.show()

print(corr['Outcome'].sort_values(ascending=False))
```



```

Outcome      1.000000
Glucose      0.466581
BMI          0.292695
Age          0.238356
Pregnancies  0.221898
DiabetesPedigreeFunction  0.173844
Insulin      0.130548
SkinThickness 0.074752
BloodPressure 0.065068
Name: Outcome, dtype: float64

```

6-Qadam: Maqsadli O'zgaruvchi Taqsimotini Vizualashtirish (Visualize Target Variable Distribution)

Maqsadli sinflar (*target classes*) (Diabetga chalingan (*Diabetes*) va Diabetga chalinmagan (*Not Diabetes*)) muvozanatlanganligini (*balanced*) tekshiring, bu esa modelni o'qitish (*model training*) va baholashga (*evaluation*) ta'sir qiladi.

- `plt.pie()`: Maqsadli o'zgaruvchi (*target variable*) 'Outcome' dagi har bir sinfning nisbatini (*proportion*) ko'rsatish uchun doiraviy diagramma (*Pie chart*).


```

plt.pie(df['Outcome'].value_counts(), labels=[
    'Diabetes', 'Not Diabetes'], autopct='%.f%%', shadow=True)

```

```
plt.title('Outcome Proportionality')
plt.show()
```

Chiqish:



7-Qadam: Xususiyatlar va Maqsadli O'zgaruvchini Ajratish (Separate Features and Target Variable)

Modellashtirish (*modeling*) uchun mustaqil o'zgaruvchilarni (*independent variables*) (xususiyatlar (*features*)) va bog'liq o'zgaruvchini (*dependent variable*) (maqsad (*target*)) alohida tayyorlang.

- `df.drop(columns=[...])`: Maqsadli ustunni (*target column*) xususiyatlardan (*features*) olib tashlaydi.
- To'g'ridan-to'g'ri ustunni tanlash (*Direct column selection*) `df['Outcome']` yordamida maqsadli ustunni (*target column*) tanlaydi.

```
x = df.drop(columns=['Outcome'])
y = df['Outcome']
```

8-Qadam: Xususiyatlarni Masshtablash: Normallashtirish va Standartlashtirish (Feature Scaling: Normalization and Standardization)

Xususiyatlarni (*features*) **umumiy diapazonga** (*common range*) yoki **taqsimotga** (*distribution*) masshtablang, bu **xususiyatlar kattaligiga** (*feature magnitudes*) sezgir bo'lgan ko'plab **MO algoritmlari** (*ML algorithms*) uchun muhimdir.

1. Normallashtirish (Min-Max Masshtablash) (*Normalization (Min-Max Scaling)*)

- Xususiyatlarni 0 va 1 oralig'ida qayta masshtablaydi (*Rescales features between 0 and 1*).
- k-NN (*k-Nearest Neighbors*) va neyron tarmoqlar (*neural networks*) kabi algoritmlar uchun yaxshi.
- Sinf (*Class*): sklearn (*scikit-learn*) dagi `MinMaxScaler`.
- `.fit_transform()`: Ma'lumotlardan minimal/maksimal (*min/max*) qiymatlarni o'rganadi (*Learns*) va masshtablashni (*scaling*) qo'llaydi.

```
scaler = MinMaxScaler()
X_normalized = scaler.fit_transform(X)
print(X_normalized[:5])
```

Chiqish:

```
[[0.35294118 0.74371859 0.59016393 0.35353535 0.          0.50074516
 0.23441503 0.48333333]
 [0.05882353 0.42713568 0.54098361 0.29292929 0.          0.39642325
 0.11656704 0.16666667]
 [0.47058824 0.91959799 0.52459016 0.          0.          0.34724292
 0.25362938 0.18333333]
 [0.05882353 0.44723618 0.54098361 0.23232323 0.11111111 0.41877794
 0.03800171 0.          ]
 [0.          0.68844221 0.32786885 0.35353535 0.19858156 0.64232489
 0.94363792 0.2          ]]
```

2. Standartlashtirish (*Standardization*)

- Xususiyatlarni o'rtacha qiymati $mean = 0$ va standart og'ishi $standard deviation = 1$ bo'ladigan qilib o'zgartiradi (*Transforms*), bu normal taqsimlangan xususiyatlar (*normally distributed features*) uchun foydalidir.
- Sinf (*Class*): sklearn (*scikit-learn*) dagi `StandardScaler`.

```
scaler = StandardScaler()
X_standardized = scaler.fit_transform(X)
print(X_standardized[:5])
```

Chiqish:

```
[[ 0.63994726  0.84832379  0.14964075  0.90726993 -0.69289057  0.20401277
  0.46849198  1.4259954 ]
 [-0.84488505 -1.12339636 -0.16054575  0.53090156 -0.69289057 -0.68442195
 -0.36506078 -0.19067191]
 [ 1.23388019  1.94372388 -0.26394125 -1.28821221 -0.69289057 -1.10325546
  0.60439732 -0.10558415]
 [-0.84488505 -0.99820778 -0.16054575  0.15453319  0.12330164 -0.49404308
 -0.92076261 -1.04154944]
 [-1.14185152  0.5040552  -1.50468724  0.90726993  0.76583594  1.4097456
  5.4849091  -0.0204964 ]]
```

Afzalliklar (*Advantages*)

- Ma'lumot sifatini yaxshilaydi (*Improves Data Quality*): Yaxshiroq tahlil (*better analysis*) uchun xom ma'lumotlarni (*raw data*) tozalaydi (*cleans*) va tashkil etadi (*organizes*).
- Model aniqligini oshiradi (*Enhances Model Accuracy*): Shovqinni (*noise*) va nomaqbul ma'lumotlarni (*irrelevant data*) olib tashlaydi, bu esa aniqroq prognozlarga (*more precise predictions*) olib keladi.
- Haddan tashqari moslashuvni kamaytiradi (*Reduces Overfitting*): Chetga chiqqan qiymatlarni (*outliers*) va ortiqcha xususiyatlarni (*redundant features*) hal qiladi, bu esa modelning umumlashtirish qobiliyatini (*model generalization*) yaxshilaydi.
- O'qitishni tezlashtiradi (*Speeds Up Training*): Samarali masshtablangan ma'lumotlar (*Efficiently scaled data*) hisoblash vaqtini (*computation time*) kamaytiradi.
- Algoritm mosligini ta'minlaydi (*Ensures Algorithm Compatibility*): Ma'lumotlarni mashinaviy o'qitish modellari (*machine learning models*) uchun mos formatlarga (*suitable formats*) o'tkazadi.

